Lista II: Análise de Dados da CAPES

Dan Nogueira da Silva

2024-03-05

Nesta lista, o objetivo será analisar a produção de teses e dissertações de programas de pósgraduação notas 4, 5, 6 e 7 na Capes, das áreas de Sociologia, entre os anos de 1987 e 2022. A análise explora a evolução da produção ao longo do tempo, a distribuição por subtemas e a concentração regional das defesas, seguindo um recorte de palavras-chave específico. Os dados foram processados e analisados utilizando o software R e pacotes para análise de dados e visualização.

Tendências na produção de teses e dissertações em Sociologia

Metodologia

A análise foi realizada utilizando dados coletados de duas fontes:

Banco de dados de defesas de teses e dissertações da CAPES: Contém informações sobre as defesas realizadas entre 1987 e 2022, incluindo dados sobre o programa, a instituição, o autor, o título, as palavras-chave e a área de avaliação.

Banco de dados de programas de pós-graduação da CAPES: Contém informações sobre os programas de pós-graduação, incluindo o código do programa, o estado e o conceito CAPES.

1. Importando arquivos e arrumando a base

Para começar a análise, foi preciso importar a base de dados contendo as dissertações e teses de programas na CAPES. Optei por utilizar a função map_df. Nesse caso, a map_df é mais prática que o laço de repetição, por economizar linhas e espaço de memória.

Usando map_df é possível combinar todas as planilhas contendo as teses e dissertações defendidas entre 1987 a 2022, em um único tibble. Como resultado, a planilha possui 13 variáveis: código do programa, ano, sigla, instituição, nome do programa, grande área, área de conhecimento, área de avaliação, autor, titulo, nivel, palavras-chave e resumo. Cada observação diz respeito a uma defesa.

```
programas <- import("programas.csv")</pre>
```

Em seguida, usei a função import() do pacote rio para carregar a planilha com informações sobre os programas de pós-graduação. A planilha resultante possui 3 variáveis: código do programa, estado e conceito CAPES. Cada observação diz respeito a um programa de pós-graduação.

Para concatenar as informações sobre os programas com as informações sobre as defesas, utilizei a função left_join para juntar as informações dos programas partindo de uma variável em comum: o código do programa.

```
defesas_e_programas <- defesas |>
  left_join(programas, by = c("codigo_programa" = "CD_PROGRAMA"))
  view(defesas_e_programas)
```

Ao analisar a nova base, percebi alguns missings na variável UF. Tentei arrumar a lista me guiando a partir da coluna siglas_ies. Além disso, incluí a variável regiao, que vai ser útil mais à frente.

```
banco_tidy <- defesas_e_programas |>
  mutate(UF = case_when(
    str_detect(sigla_ies, "RJ|RIO|UENF|UFF|UCAM") ~ "RJ",
    str_detect(sigla_ies, "SP|UNICAMP") ~ "SP",
    str_detect(sigla_ies, "ES|UVV") ~ "ES",
    str_detect(sigla_ies, "AC") ~ "AC",
    str_detect(sigla_ies, "AL") ~ "AL",
    str_detect(sigla_ies, "AP") ~ "AP",
    str_detect(sigla_ies, "UFAM") ~ "AM",
    str_detect(sigla_ies, "BA") ~ "BA",
    str_detect(sigla_ies, "CE|FJN|UFC") ~ "CE",
    str_detect(sigla_ies, "DF|UNB") ~ "DF",
    str_detect(sigla_ies, "GO|UFG") ~ "GO",
    str detect(sigla ies, "MA") ~ "MA",
    str_detect(sigla_ies, "MT") ~ "MT",
    str_detect(sigla_ies, "MS|UFGD") ~ "MS",
    str_detect(sigla_ies, "MG") ~ "MG",
    str_detect(sigla_ies, "PA") ~ "PA",
    str_detect(sigla_ies, "PB|UFCG") ~ "PB",
    str_detect(sigla_ies, "PR|UEL") ~ "PR",
    str_detect(sigla_ies, "PE|UNIVASF") ~ "PE",
    str_detect(sigla_ies, "PI") ~ "PI",
    str_detect(sigla_ies, "RN") ~ "RN",
    str_detect(sigla_ies, "RS|UFRGS") ~ "RS",
```

```
str_detect(sigla_ies, "R0") ~ "R0",
str_detect(sigla_ies, "RR") ~ "RR",
str_detect(sigla_ies, "SC") ~ "SC",
str_detect(sigla_ies, "SE") ~ "SE",
str_detect(sigla_ies, "T0") ~ "T0",
    TRUE ~ "Outros"
)) |>
mutate(regiao = case_when(
    UF %in% c("AM", "RR", "AP", "PA", "T0", "R0", "AC") ~ "Norte",
    UF %in% c("MA", "PI", "CE", "RN", "PE", "PB", "SE", "AL", "BA") ~ "Nordeste",
    UF %in% c("MT", "MS", "G0", "DF") ~ "Centro Oeste",
    UF %in% c("PR", "SC", "RS") ~ "Sul",
    UF %in% c("SP", "RJ", "ES", "MG") ~ "Sudeste",
    TRUE ~ "Não reportado"
))
```

Após "dar uma arrumada" no banco, filtrei dele apenas as observações que continham programas com notas CAPES maiores que 4 em minha área de interesse (sociologia).

```
sociologia <- banco_tidy |>
  filter(CONCEITO != "NA|3|A") |>
  filter(str_detect(nome_programa, "SOCIOLOGIA"))
```

Por algum motivo os *missings* continuavam a ser considerados quando eu utilizava a lógica CONCEITO == 4|5|6|7, então achei melhor filtrar usando a negação das observações indesejadas.

2. Seleção de palavras-chave

Para o meu desenho de pesquisa, as 3 palavras-chave mais interessantes são ensino superior, desigualdade e educação. Filtrei a base para mostrar apenas defesas que se enquadravam em pelo menos uma das 3 palavras-chave.

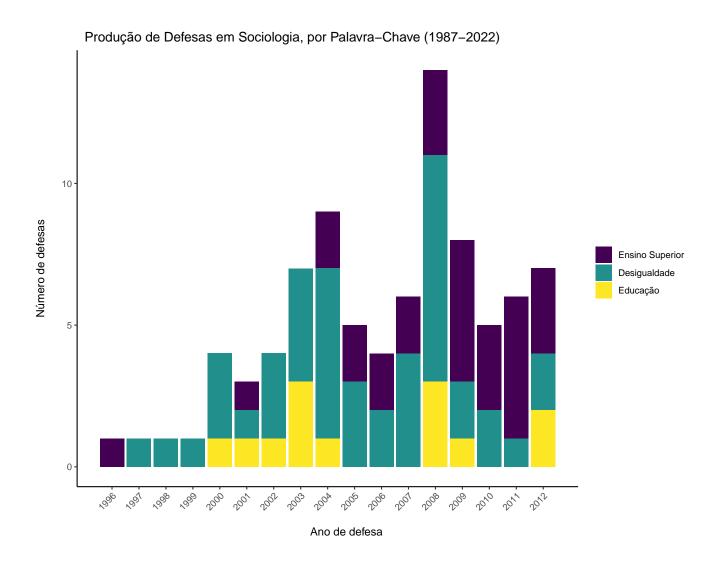
```
trabalhos_relevantes <- sociologia |>
filter(str_detect(palavras_chave, "ensino superior|desigualdade|educação"))
```

3. Evolução ao longo do tempo

O objetivo aqui é criar uma visualização que reporte de forma sucinta e informativa a produção de teses e dissertações do meu interesse, por ano. Sendo assim, era preciso criar uma coluna para contagem das ocorrências de defesas por ano e palavra-chave. Adicionei a variável subtema, que classificava as defesas por palavra-chave correspondente. Depois contei quantas ocorrências cada variável ano haviam em relação a cada observação da variável subtema. Dessa forma consigo um output com uma tabela 'long' contendo 3 variáveis: ano, subtema e frequência. Assim consigo os dados ideais para visualizar a primeira tabela da lista!

```
ocorrencias_por_ano <- trabalhos_relevantes |>
mutate(subtema = case_when(
   str_detect(palavras_chave, "ensino superior") ~ "Ensino Superior",
   str_detect(palavras_chave, "desigualdade") ~ "Desigualdade",
   str_detect(palavras_chave, "educação") ~ "Educação",
   TRUE ~ "Outros" # catchError
)) |>
count(ano, subtema) |>
rename(frequencia = n)
```

Para visualizar, escolhi o gráfico de barras empilhadas para ver quantas observações foram feitas para cada ano do eixo x, qualificando a frequência por palavras-chave. Assim consigo ver quantas teses foram defendidas em cada ano, ao mesmo tempo em que consigo ver a frequência de cada subtema que considerei relevante para minha pesquisa. O gráfico em barras empilhadas é perfeito para visualizar a relação entre uma variável numérica e uma variável categórica.



4. Diferenças regionais

Para esta seção, foram calculados o total de trabalhos defendidos ao longo de todo o período por estado a fim de criar duas visualizações: em uma, é reportada a frequência de trabalhos por região; em outra, a frequência de trabalhos por unidade da federação.

Mapeando da frequência de trabalhos por Unidade da Federação usando geobr

Usando as funções read_state() e read_region() do pacote geobr é possível obter as coordenadas de todos os estados e regiões do Brasil. Para evitar outputs indesejados no documento final, utilizei o atributo showProgress = FALSE.

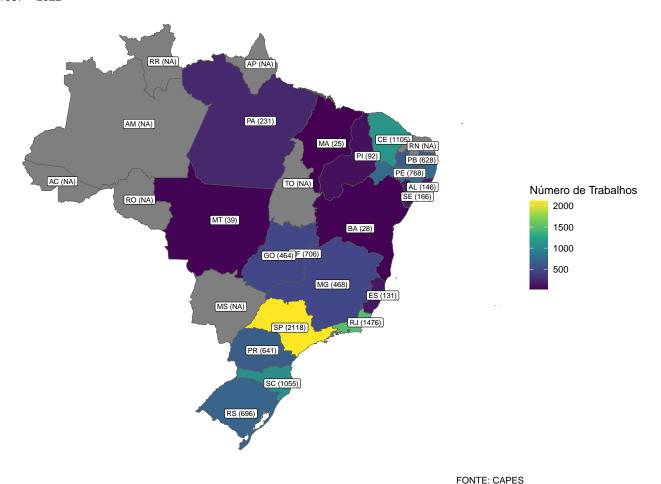
```
coordenadas_estados <- read_state(showProgress = FALSE)
coordenadas_regioes <- read_region(showProgress = FALSE)</pre>
```

Em seguida, para garantir uma boa visualização das frequências, as defesas foram agrupadas por estado. Depois foi somado o total de trabalhos por unidade da federação, e esses dados foram unidos com as coordenadas correspondentes, extraídas do pacote geobr.

```
defesas_por_estado <- sociologia |>
  group_by(UF) |>
  summarise(total_trabalhos_uf = n()) |>
  full_join(coordenadas_estados, by = c("UF" = "abbrev_state")) |>
  st_as_sf()
```

Mapa representando a frequência de defesas por estado

Frequência de Trabalhos de Sociologia Defendidos por Unidade da Federação 1987 – 2022

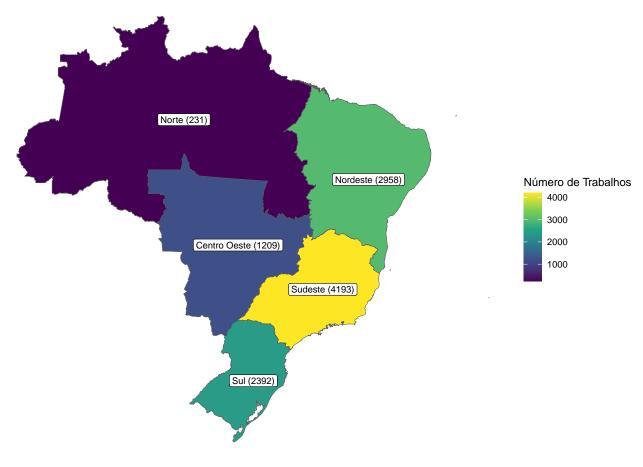


É possível observar que São Paulo (SP) é o estado que mais produz trabalhos na área da sociologia atuantes nas pesquisas sobre educação, desigualdades e ensino superior. Seguido de Rio de Janeiro (RJ) e Ceará (CE), com 2118, 1476 e 1105 produções de pós-graduandos, respectivamente.

Mapa da frequência de trabalhos por região

Utilizando a mesma lógica construída no mapa anterior, o mapa abaixo resume o número de trabalhos defendidos entre as regiões do Brasil.

Frequência de Trabalhos de Sociologia Defendidos por Região 1987 – 2022



FONTE: CAPES

5. Produção por programa

O objetivo é obter uma tabela contendo o número de trabalhos defendidos pelos 10 programas com maior produção entre 1987 e 2022. Nesta seção, foi calculado o total de teses e dissertações defendidas por cada programa de pós-graduação em sociologia.

```
trabalhos_por_programa <- sociologia |>
  mutate(tese_ou_defesa = case_when(
    str_detect(nivel, "Mestrado|MESTRADO|MESTRADO PROFISSIONAL") ~ "dissertacao",
    str_detect(nivel, "Doutorado|DOUTORADO") ~ "tese",
    )) |>
    count(sigla_ies, nome_programa, tese_ou_defesa, CONCEITO) |>
    rename(trabalhos = n)

trabalhos_por_programa <- pivot_wider(trabalhos_por_programa, names_from = tese_ou_defesa, values
    mutate(tese = case_when(
        tese > 0 ~ tese,
```

```
TRUE ~ 0
)) |>
mutate(total_defesas = dissertacao + tese) |>
arrange(-total_defesas)|>
slice(1:10)|>
select(-total_defesas)
```

Transformei a coluna tese_ou_defesa em duas variáveis: dissertacao e tese, alongando a base de trabalhos_por_programa. Para o cálculo, utilizei a função case_when() para filtrar os níveis (mestradodoutorado) e contabilizar o número de trabalhos totais.

A tabela final possui 4 informações importantes: nome do programa, nota CAPES, total de dissertações e total de teses defendidas no programa.

Tabela 1: Programas com o maior número de trabalhos em sociologia

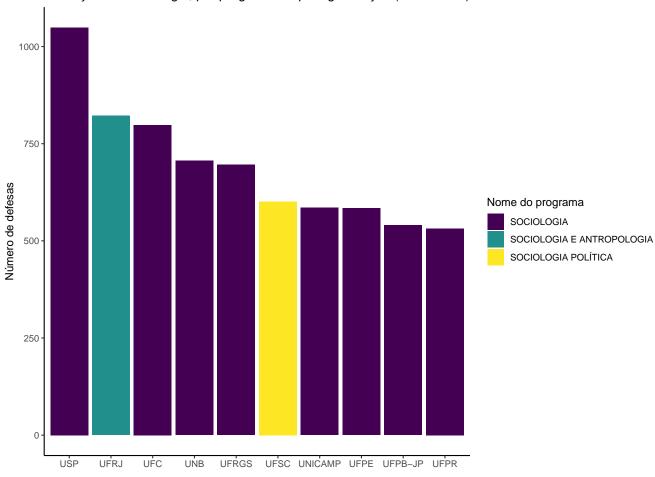
Estatísicas descritivas de teses e dissertações de programas de pós-graduação 1987-2022

Sigla	Nome do Programa	Nota CAPES	Dissertações	Teses
USP	SOCIOLOGIA	6	489	560
UFRJ	SOCIOLOGIA E ANTROPOLOGIA	7	530	292
UFC	SOCIOLOGIA	5	533	265
UNB	SOCIOLOGIA	7	378	328
UFRGS	SOCIOLOGIA	7	451	245
UFSC	SOCIOLOGIA POLÍTICA	5	448	153
UNICAMP	SOCIOLOGIA	6	434	151
UFPE	SOCIOLOGIA	5	356	228
UFPB-JP	SOCIOLOGIA	5	379	161
UFPR	SOCIOLOGIA	5	363	169

Fonte: CAPES.

Visualização em barras dos programas com maior número de trabalhos em sociologia

Produção em Sociologia, por programa de pós-graduação (1987-2022)



Sigla da instituição de ensino superior

6. Exportação

Nesta última etapa, foi criada uma base menor contendo apenas as seguintes variáveis: ano, estado, programa, título, resumo e autor(a). Essa base está exportada em uma planilha .csv, para consultas futuras.

```
resumo <- trabalhos_relevantes |>
select(ano, UF, nome_programa, titulo, resumo, autor)
```

```
resumo |>
  gt() |>
  tab_header(title = "Trabalhos relevantes para minha pesquisa") |>
  tab_source_note(source_note = "Fonte: CAPES.") |>
  cols_label(ano = md("**Ano**"), UF = md("**Estado**"), nome_programa = md("**Programa**"), titu
  text_transform(
  locations = cells_body(columns = resumo),
  fn = function(x) {
    substr(x, 1, 80)  # Encurta o texto
  }
)
```

Ano	Estado	Programa	Título
1996	BA	SOCIOLOGIA	Arranjos Familiares e Desigualdades Raciais Entre Trabal
1997	SP	SOCIOLOGIA	O batismo da instituição: atraso, educação e modernidade
1998	RJ	SOCIOLOGIA E ANTROPOLOGIA	Educação, gênero e cor: práticas sociais e representações
1999	SP	SOCIOLOGIA	"O Estatal, o público e o privado em educação: tensões e
2000	SP	SOCIOLOGIA	"Terapias, Terapeutas e Educação em Saúde na Pós-Made
2000	SP	SOCIOLOGIA	Caminhos e descaminhos da socialização política na pasto
2000	SC	SOCIOLOGIA POLÍTICA	Uma Universidade Crítica ou Funcional. As Propostas e a
2000	RJ	SOCIOLOGIA E ANTROPOLOGIA	Do assimilacionismo ao multiculturalismo: educação e rep
2001	RJ	SOCIOLOGIA E ANTROPOLOGIA	A pobreza na visão das elites.
2001	RJ	SOCIOLOGIA E ANTROPOLOGIA	Sociologia da Sociologia da Educação: caminhos e desafio
2001	RJ	SOCIOLOGIA E ANTROPOLOGIA	Querendo modificar "destinos" sociais: experiências e pro-
2002	PE	SOCIOLOGIA	Habitus e Reflexidade do Trabalhador Brasileiro a partir
2002	SC	SOCIOLOGIA POLÍTICA	Análise da Evolução dos Gastos Públicos Municipais em S
2002	SC	SOCIOLOGIA POLÍTICA	A AVALIAÇÃO DO SISTEMA DE ENSINO SUPERIOR
2002	DF	SOCIOLOGIA	O PIBIC e a difusão da carreira científica na Universidad
2003	SP	SOCIOLOGIA	Mas afinal que elite é essa? Elitização/deselitização no Ve
2003	RJ	SOCIOLOGIA E ANTROPOLOGIA	Por que hoje no Brasil mais mulheres buscam o ensino su
2003	GO	SOCIOLOGIA	ESCOLA SEM LIMITES: VIOLÊNCIA, INDISCIPLINA
2003	GO	SOCIOLOGIA	POLÍTICA SOCIAL E PRÁTICA SINDICAL NO CAMI
2003	SP	SOCIOLOGIA	RACISMOS E ANTI-RACISMOS NA PERSPECTIVA D
2003	PR	SOCIOLOGIA	TRABALHO INFANTIL: uma análise das tentativas de s
2003	DF	SOCIOLOGIA	De Casa à Escola: caminho fecundo para o enfrentamento
2004	RJ	SOCIOLOGIA E ANTROPOLOGIA	Herdeiros ou sobreviventes: mobilidade social no Ensino S
2004	RJ	SOCIOLOGIA E ANTROPOLOGIA	A sociologia volta à escola: um estudo dos manuais de so
2004	RJ	SOCIOLOGIA E ANTROPOLOGIA	Desigualdades "Raciais" e Ensino Superior: Um estudo so
2004	SP	SOCIOLOGIA	A ESCOLA: MUNDO ESTRANHO AO PROFESSOR (F
2004	PR	SOCIOLOGIA	REPRESENTAÇÕES SOCIAIS E POLÍTICA DE REFO
2004	RS	SOCIOLOGIA	Conexões sociológicas entre questão social e a questão cri

2004	RS	SOCIOLOGIA	Transformações do trabalho e política pública de qualifica
2004	DF	SOCIOLOGIA	Formação e Fixação de Pesquisadores na Região Norte do
2004	DF	SOCIOLOGIA	A tendência concentradora do desenvolvimento científico
2005	RJ	SOCIOLOGIA E ANTROPOLOGIA	Informática, educação e desigualdade social nas escolas pu
2005	RJ	SOCIOLOGIA E ANTROPOLOGIA	Estratégias coletivas em torno da formação universitária:
2005	SC	SOCIOLOGIA POLÍTICA	O ProInfo em Santa Catarina: uma análise sociotécnica d
2005	RS	SOCIOLOGIA	A dinâmica da educação superior: um estudo sobre as un
2005	RS	SOCIOLOGIA	A discriminação racial em números e palavras. Estudo sol
2006	RJ	SOCIOLOGIA E ANTROPOLOGIA	Inclusão social e assimetria de informação no sistema de I
2006	RJ	SOCIOLOGIA E ANTROPOLOGIA	Educação profissional e aprendizagem do trabalho na nov
2006	SP	SOCIOLOGIA	Os andaimes do novo voluntariado
2006	SP	SOCIOLOGIA	Palavra e terra: princípios de uma pedagogia guarani
2007	PB	SOCIOLOGIA	Experiências Individuais de Envelhecimento: estigmas e a
2007	PE	SOCIOLOGIA	ARTICULAÇÃO ENTRE DISCURSOS GLOBAIS E LO
2007	RJ	SOCIOLOGIA E ANTROPOLOGIA	Novas tecnologias do ponto de vista docente.
2007	RJ	SOCIOLOGIA E ANTROPOLOGIA	Nem sucesso, nem fracasso: uma abordagem etnográfica d
2007	RJ	SOCIOLOGIA E ANTROPOLOGIA	Operários negros - Relação entre cor e trabalho na nova ir
2007	PR	SOCIOLOGIA	EDUCAÇÃO E RELAÇÕES RACIAIS: UM ESTUDO D
2008	PE	SOCIOLOGIA	ANÁLISE DO DISCURSO POLÍTICO-IDEOLÓGICO D
2008	AL	SOCIOLOGIA	EDUCAÇÃO E IDEOLOGIA NO LIVRO DIDÁTICO:un
2008	RJ	SOCIOLOGIA E ANTROPOLOGIA	Identidade e educação para a fé Bahá'i no Brasil: um est
2008	RJ	SOCIOLOGIA E ANTROPOLOGIA	Expansão do Ensino Superior e mercado de trabalho: o ca
2008	RJ	SOCIOLOGIA E ANTROPOLOGIA	Ser "Trabalhador Flexível e Competente": um olhar sobre
2008	SP	SOCIOLOGIA	VOCÊ VAI ME SERVIR : DESIGUALDADE, PROXIMI
2008	SP	SOCIOLOGIA	Exclusão social e ruptura dos laços sociais: análise crítica
2008	PR	SOCIOLOGIA	NEM EVA, NEM MARIA: AS SUBJETIVAÇÕES EM C
2008	RS	SOCIOLOGIA	A escolha do curso superior dos vestibulandos da UFRGS
2008	RS	SOCIOLOGIA	Percepção das desigualdades socioeconômica: estudo sobr
2008	RS	SOCIOLOGIA	Transformações da educação superior na Europa: a reform
2008	GO	SOCIOLOGIA	O gênero na escola: a educação física em questão
2008	DF	SOCIOLOGIA	A construção da agenda de gênero no sistema educacional
2008	DF	SOCIOLOGIA	Projetos de futuro de jovens universitários no Distrito Fed
2009	RJ	SOCIOLOGIA E ANTROPOLOGIA	Acesso e permanência nos cursos de graduação da UFRJ:
2009	RJ	SOCIOLOGIA E ANTROPOLOGIA	Transgressões ou reprodução? Discursos de homens e mul
2009	RJ	SOCIOLOGIA E ANTROPOLOGIA	Uma Escola de Luta: Análise dos significados da educação
2009	MG	SOCIOLOGIA	Deslocamentos urbanos e desigualdades.sociais: um estud
2009	SP	SOCIOLOGIA	A EDUCAÇÃO NO PERÍODO DE TRANSIÇÃO SOCIA
2009	SP	SOCIOLOGIA	Elite Política Brasileira e a renegociação das dívidas do C
2009	GO	SOCIOLOGIA	O mundo imaginado, mas nem tanto de Carmo Bernardes
2009	DF	SOCIOLOGIA	A desigualdade racial de renda no Brasil: 1976-2006
2010	SP	SOCIOLOGIA	O charme (in)discreto do gosto burguês paulista: Estudo
2010	SP	SOCIOLOGIA	TRABALHO INFORMAL E DESEMPREGO: DESIGUA
2010	SP	SOCIOLOGIA	Educação Superior, Emprego e Renda: uma relação probl
2010	SP	SOCIOLOGIA	Estado, Sociedade e Políticas Públicas de Educação: O P
2010	DF	SOCIOLOGIA	Ações afirmativas no Brasil: um estudo de caso sobre o E
2011	PB	SOCIOLOGIA	"A Presença da Cultura Popular em Três Grandes Evento
2011	RJ	SOCIOLOGIA	Consumos cultural como diversidad expresiva. Desigualda
			·

2011	RJ	SOCIOLOGIA	A Vila Acaba Mundo e a Construção de Mundos Possívei
2011	SP	SOCIOLOGIA	"Os pioneiros: a desigualdade digital entre membros das o
2011	SP	SOCIOLOGIA	Retrato Cultural, Montevidéu entre Cumbias, Tambotes e
2011	SP	SOCIOLOGIA	Entretempos: experiências de vida e resistência entre os l
2012	RJ	SOCIOLOGIA E ANTROPOLOGIA	Estado, mercado e pobreza na visão das elites no Brasil e
2012	RJ	SOCIOLOGIA E ANTROPOLOGIA	Ainda somos os mesmos: classificação, organização e etho
2012	RJ	SOCIOLOGIA E ANTROPOLOGIA	Tecendo rede: usos tecnológicos por jovens em uma metró
2012	RJ	SOCIOLOGIA POLÍTICA	A POLÍTICA DE AÇÃO AFIRMATIVA EM PAUTA: D
2012	SP	SOCIOLOGIA	"Formação e identidade profissional: a trajetória de egress
2012	SP	SOCIOLOGIA	"Classe, raça e ação afirmativa: a política de inclusão soc
2012	SP	SOCIOLOGIA	"Ampliação do acesso ao ensino superior privado lucrativo

Fonte: CAPES.

write_csv(resumo, "resumo.csv")

Conclusão

A experiência de fazer essa lista foi incrível. Pela primeira vez me senti pesquisador durante o mestrado. Essa lista me fez entender o fluxo de limpeza de bases de dados, me fez aprender a aprender, me trouxe também algumas noites sem dormir tentando achar formas de aprimorar o código e a documentação do mesmo. Em resumo, a jornada de elaboração da lista foi desafiadora e estimulante. Ao longo do processo, aprimorei minhas habilidades em análise de dados, além de reafirmar minha paixão por Sociologia e Programação.

Enfrentei desafios técnicos e pessoais, dediquei noites ao trabalho árduo, mas essa experiência desafiadora com certeza reforçou meu compromisso com a pesquisa e me deixou ansioso para continuar seguindo por esse caminho. Quero escrever todos os meus trabalhos em .qmd a partir de agora.